Sprawozdanie - Latent Semantic Indexing

Arkadiusz Kraus

21 maja 2019

1 Zadanie

Zadanie polegało na zastosowaniu metody Latent Semantic Indexing (LSI), aby w zbiorze tektów móc wyszukiwać te związane z podaną frazą.

2 Zbiór danych

Zbiór danych jaki zastosowałem pochodzi ze strony https://www.kaggle.com/snapcrack/all-the-news. Jest to zbiór artykułów z amerykańskich gazet z lat 2016-2017 o różnej tematyce. Jest złożony z ponad 140 tys. tekstów.

3 Zastosowane przekształcenia

Na początku przetwarzamy wstępnie przetwarzamy zbiór artykułów, aby później móc skuteczniej w nim wyszukiwać:

3.1 Zbiór użytych słów

Dla każdego artykułu bierzemy wszyskie użyte słowa i tworzymy wektor słów dla wszystkich tekstów. Dla kolejnych podzbiorów artykułów posiada on następujące wielkości.

liczba artykułów	rozmiar wektora		
1000	44 tys.		
10000	140 tys.		
50000	230 tys.		
wszystkie(142572)	400 tys.		

3.2 Wstępne przetworzenie

Liczba słów uzyskana w poprzednim podpunkcie jest bardzo duża, aby uczynić algorytm wydajniejszym staramy się zredukować ten wektor. We wstępnym przetworzeniu pomijamy wielkość liter oraz znaki interpunkcyjne.

3.3 Stemming

Wiele słów może występować w różnych formach np. take i taking. Nas jednak interesuje sam fakt czynności, a nie koniecznie np. czas w jakim była wykonywana. Innym przypadkiem jest też liczba mnoga rzeczownika, gdzie nadal interesuje nas sam rzeczownik. Dlatego stosujemy algorytm stemmingu (dokładniej Porter Stemmer), doprowadzamy słowa do wspólnego rdzenia i usuwamy duplikaty. W połączeniu z poprzednim krokiem pozwala to znacząco zredukowac rozmiar wektora:

liczba artykułów	rozmiar wektora
1000	24 tys.
10000	70 tys.
50000	127 tys.
wszystkie(142572)	234tys.

3.4 Stopwords

Stopwords to zbiór słów takich jak przyimki itp, które występują bardzo często we wszelkich tekstach. Nie mają one większego znaczenia dla treści dlatego również można je pominąć. Nie redukuje to wielkości wektora znacznie (o około 150 słów), jednak zwiększa jakość wyszukiwania.

3.5 Tworzenie macierzy rzadkiej

Chcemy teraz utworzyć macierz, która jako wiersze będzie przyjmować kolejne artukułu, a jako kolumny kolejne słowa ze zbioru. Wartością w komórce a_ij macierzy będzie liczba wystąpień j-tego słowa w i-tym artykule. Zauważmy, że będzie to macierz rzadka ponieważ artyukuły mają ok. 4000 tys słów, a wektor słów jest znacznie większy. Dodatkowo jeśli artykuł jest na jakis temat to słowa często się w nim powtarzają. Aby przyśpieszyć obliczenia (i w ogóle je umożliwić) stosujemy więc przechowywanie w postaci macierzy rzadkiej (dokładniej CSR - Compressed Sparse Row).

3.6 IDF

W celu zwiększenia jakości wyszukiwania stosujemy Inverse Document Frequency (IDF). Pozwala on nam zmniejszyć znaczenie słów, które występują w wielu artykułach i zwiększyć tych, które rzadko.

3.7 Normalizacja

Normalizacja pozwala uniezależnić korelację od długości tekstu. Wykonujemy ją od razu, aby potem przyspieszyć wyszukiwanie, aby nie trzeba było obliczać normy za każdym razem.

3.8 Odszumianie

W celu redukcji szumów stosujemy algorytm SVD i wybieramy k najciekawszych wartości własnych. Co ciekawe zwiększa to liczbę niezerowych elementów macierzy z ok 1-2 mln do 87 mln dla 10 tys. artykułów.

4 Obliczenia

Problem ten jest bardzo wymagający obliczeniowo oraz pamięciowo. Przechowanie macierzy wielkości liczba artykułów * liczba słów dla większej ilości artukułów skutkuje skończeniem pamięci. W pliku logs znajdują się czasy wstępnego przetworzenia dla 50000 i wszystkich artykułów. Wyszukiwanie po przetworzeniu i odczytaniu wcześniejszej macierzy jest również zależne od ilości artykułów i dla większej ilości jeszcze trochę mu brakuje względem czasów osiągnych przez Google.

liczba artykułów	rozmiar wektora	rozmiar	czas prze-	czas wyszukania
		wektora	tworzenia	
		po prze-		
		tworzeniu		
1000	44 tys	24 tys	natychmiast	natychmiast
10000	140 tys	70 tys	1 min	1 s
50000	230 tys	127 tys	35 min	15 sek
wszystkie(142572)	400 tys	234 tys	2,5h	1 min

Niestety dla 50000 oraz dla wszystkich artykułów stworzenie macierzy po dekompozycji SVD okazało się zbyt czasochłonne. Przy próbie utworzenia normalnej macierzy po dekompozycji dla np. 200 wartości własnych otrzymywałem brak pamięci, natomiast dla macierzy rzadkich obliczenia trwały w nieskończoność (obliczenia na nich są czasochłonnymi operacjami). Dlatego dla tych wielkości wyszukiwarka używa macierzy bez odszumienia.

5 Wyniki

Aplikacja jest podzielona na dwie części - jedna odpowiadająca za indeksowanie i druga wyszukująca treści dla zadanej frazy. Obie częsci działają poprawnie. Poniżej znajduje się przykład:

Hurricane Matthew Toll Climbs to at Least 17 as North Carolina Suffers Record-Breaking Flooding - The New York Times

Correlation: 0.08182207146267585

Hurricane Matthew was downgraded to a cyclone early Sunday morning as it hit North Carolina and Virginia with a weakened but still powerful punch. Dispatches from our reporters on the ground a live storm tracker map and answers to reader questions will be updated below. ■ The storm's death toll in the United States has climbed to at least 17. Gov. Pat McCroy of North Carolina said on Sunday morning that his state's toll had risen to eight. Officials in Georgia confirmed three deaths on Saurday. At least six fatallities in Florida have been attributed to the storm. Nearly 900 people have died in Halidi, according to a Reuters report based on information from civil protection and local officials. Be Bands of beyen y rain are leading to flooding in parts of seastern North Carolina, according to the National Hurricane Center, which may result in flooding and flash flooding elsewhere in the region. Forecasters wamed that areas along the Neuse River in Goldsboro, N. C. could experience flooding worse than the devastanting inundation that followed Hurricane Floyd in 1999. The river was projected to this on. Monday, suprassing the record of 28.0 feet caused by Floyd. ■ In Georgia, the storm created a record surge at Tybee Island, near the state's border with South Carolina. The surge reached 12.5 feet, according to the Chatham County Emergency Management Agency, which exceeded the previous high of 12.2 feet, set during Hurricane David in 1979. To cover the storm and its aftermath, The New York Times has journalists deployed along the it path. Follow our correspondents on Twitter. The storm's assault on North Carolina extended into Sunday, and the governor said at least seven people had been killed in the state. "I wouldn't assume that there aren't people clinging for life right move in house shall be a sunday and the governor said at least seven people had been killed in the state." I wouldn't assume that there aren't people clinging for life right move in house shall be provided to th

Rysunek 1: Wyniki wyszukiwania dla hasła "weather rain south"

Tropical Storm Hermine Leaves Trail of Power Failures - The New York Times

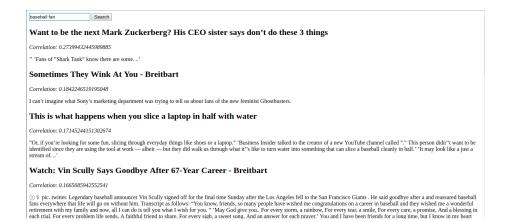
The remants of what had been Hurricane Hermine swept up and along the Eastern Seaboard on Saturday, disrupting the holiday weekend in much of the coastal South while preparing to bedevil the northeast well into the week. The storm, which made its landfall early Friday near St. Marks, Fla. as a Category 1 hurricane, led to hundreds of thousands of power failures and flooded roadways. In Florida, dealt its first direct strike by a hurricane in nearly 11 years, the Tallahassee area was particularly hard hit, and officials said it could be almost a week before electricity was fully restored. "We still have a lot of work to do following the storm," Gov. Rick Scott of Florida said at a new sconference on Sustrady in Tallahastee, the state capital. "Well continue to spend the coming days assessing the damage and responding to the needs of our Florida families." Mr. Scott said there was "significant damage" in the state, including "a lot of downed power lines." Residents and officials described destored businesses, boats set adrift, cumbled sea walls and battered homes. The National Hurricane Center said days make the state or the state of the state of

Hurricane Matthew's Toll Rises Flooding Strands 1,500 in North Carolina - The New York Times

Correlation: 0.07677973382307797

Rysunek 2: Wyniki wyszukiwania dla hasła "weather rain south" część druga

Dla większej ilości artukułów gdzie nie było możliwe przeprowadzenie SVD zdarzają się jednak wyniki takie jak np. ten:



Rysunek 3: Przykład wyniku z szumami

W tym przypadku dopiero któryś wynik jest taki jak powinien, a na początku jest szum. To samo zapytanie przy mniejszej ilości artykułów i z usuniętym szumem wygląda następująco:



Rysunek 4: Przykład wyniku bez szumu

6 Wnioski